RAG 與 Graph RAG 實作

專案資訊

項目: 傳統 RAG 與 知識圖譜增強 RAG 實作與比較

環境: Python 3.12.7

套件: requests (2.32.3) langchain (0.3.19) langchain-openai (0.3.7) pinecone (6.0.1)

networkx(3.4.2) matplotlib (3.10.1)

安裝方式: Poetry, requirements.txt

github: https://github.com/simongood/project RAG and Graph.git

執行檔:

RAG: rag query.ipvnb

graph RAG: graph query.ipynb

#總結報告前言

1. 技術文件:使用針對鞋子發霉技術文件

由 claud ai 生成 (大小: 14.7kb, 字數: 6493, 路徑: 'file\shoe-mold-technical-document.txt')

- 2. 目標: rag, graph rag 實作, 包含 比較 5 種不同複雜度問題、3 種評分定義
- 3. 對 graph rag 的理解:

針對業務:主要作用在分析深度,所以在業務上要保證其必要性,若不需要深度關係則傳統資料庫即可解 決

效率原则:對關係分析沒有大影響的放在傳統資料庫,核心:設計成小而輕的載體

4. 所以此專案針對目標:建立於針對對鞋子有黴菌問題的客服系統

#rag 實作說明

- 前製處理:文件 > 切割 > 向量化 > 存入向量資料庫

1. 切割:300 一切,60 重疊,由於本文件多為短段落,通常會是段落截斷而不會遇到重疊文本

2. 向量化: 使用 gina-embbeding v3 進行 1024 維向量化

3. 存入向量資料庫:使用 pinecone,總共儲存 32 筆段落資料

- 使用者提問:提問 > 向量化 > 比對向量資料庫 > 取 top3 放入 prompt 參考資料 > Ilm 進行回答

graph - rag 實作說明

- 提取實體與關係概念:從 100 題針對鞋子黴菌的問題集, 提出實體與關係集合(詳見備註1)
- 前置作業:提取文件知識圖譜實體關係 > 建置圖譜 > 圖譜可視化 > 將實體關係集合向量化至 pinecone
 - 1. 取出文件知識圖譜實體關係:將文檔切成不同大小,請 claud 比對已有的實體關係集合,取出最適合表示的知識圖譜資料 (路徑: 'data\graph data.json')
 - 2. 建置知識圖譜:小量資料 => 使用 networkx 存成 pkl 檔
 - 3. 可視化:(路徑: 'knowledge_graph.png')
- 使用者提問:提問 > IIm 提取實體關係 > 實體關係向量比對校正
 - > Ilm 生成新的知識圖譜比對 > 搜尋最佳知識圖譜路徑
 - > 參考所有知識圖譜路徑給予回答
 - 1. 遇到難點: Ilm 無法準確抓取提問的實體與關係, 無法配對知識圖譜

解決方案: 只要 Ilm 提出實體與關係, 再經由向量資料庫比對出top3接近的

2. 遇到難點:若原本提出3個實體,2個關係,則向量比對後將生出9個實體6個關係 若進行排列組合會有9x8x6個組合=>組合氾濫

解決方案:將9個實體6個關係給 IIm 請其重新排列為可能的知識圖譜關係

3. 待解決難點:已經盡量減少 llm 的 prompt 內容, 但還是會有小機率生成錯誤訊息

可能解決方案:將多種結構問題語句進行向量化,並提前設定好其實體與關係,若IIm 出現錯誤則 直接使用向量化搜尋已建好的問題語句,配對其實體與關係

#1. 評估指標定義:

對 graph rag 傳統 rag 定義了三項最大的差異特性, 由 prompt 給 claude 分別對其回答進行評測

- 1. 推理能力: 辨別回答中所呈現的多樣性、複雜性
- 2. 背景訊息:是否提供理解答案所需的足够背景和上下文
- 3. 資訊量匹配度:綜合考量焦點、簡潔度、額外資訊的必要性

#2. 兩個系統的回答進行評分(詳見路徑: grade.md)

		RAG			graph - RAG		
複雜度	問題	推理能力	背景訊息	資訊量匹配度	推理能力	背景訊息	資訊量匹配度
1. 基礎事實查詢 最簡單	鞋子發霉怎麼辦?	6	5	7	8	8	9
2. 比較查詢 中等複雜度	白色和黑色黴菌對鞋子的危害有什麼不同?	7	8	7	5	6	6
3. 多步驟處理查詢 中高複雜度	我的運動鞋裡外都有黴菌, 怎麼徹底清洗並防止再次發霉?	7	6	8	8	7	9
4. 專業知識與健康關聯查詢 高複雜度	長期穿著發霉的鞋子對足部健康有哪些特定風險? 特別是對糖尿病患者來說。	6	5	6	5	6	7
5. 情境分析與多方案比較查詢 最高複雜度	我在熱帶高濕地區工作,需要長期在戶外穿著皮靴, 已經出現反覆發霉問題。 請比較不同防黴方案的效果、成本和實用性, 並給出最適合我情況的解決方案。	5	4	5	8	7	9

#3. RAG VS graph - RAG 優缺點比較

值得討論的點:

- 1. 綜觀: graph RAG 在大部分狀況下,推理能力、背景訊息、資訊量匹配度都優於 RAG
- 2. 第二點: RAG 較優, 由於文本的切割段落剛好完整解釋了問題, 這種情況通過 graph 反而造成反效果
- 3. 第四點: 兩者表現皆較差, 由於技術文件內並沒有提及糖尿病患者的健康風險
- 4. 第五點: 高複雜度的差異, 若文件內容涵蓋了問題解釋, 則 graph RAG 在高複雜度問題下遠優於 RAG 結論優缺點:
 - 1. RAG: 適合當資料是一段短文本專注解釋一個問題時, 因為本身即為全局, 反而不需要做提取 (由上第2點得出; ex: 商品、電影簡介, 由短文本即完整解釋了產品)
 - 2. graph RAG: 適合在長文本能解釋多項問題時, 全局能夠回答各種不同複雜度的問題, 實體關係的抽取 提供了結構性的推理能力 (ex: 技術文件、長篇文章)
- #4. 應用方位討論(因實作方法不同於微軟 graph RAG, 所以比較內容也包括了微軟, 詳見備註1.)

	目標不交集的 短文本	長文本 - 專注業務範圍	長文本 - 專注完整解釋文本本身
RAG	0		
我的 graph - RAG		0	
微軟 graph - RAG			0

5. 改進建議

- 1. 成本:在 graph RAG 中, 提取關係與實體, 花費 IIm 價格極高, 若能使用自己微調的模型去做提取(館長), 不但可以在提取方面更符合需求, 在背後提升其推理能力, 更可以有效降低化費, 相輔相成
- graph 搜尋路線:可對使用者的問題依照不同複雜度去做設計

ex: 簡單複雜度對應到最短路徑, 高複雜度對應到三條最短路逕

3. rag 補充知識點: graph 還是會有不滿意的回答, 針對蒐集客戶問題不滿意回答的問題, 建立短文件解釋, 作為補充知識點搭配 graph RAG

備註 1.

提取實體與關係概念:

1. 微軟 graph - rag 概念:將所有實體與關係提出,觀察 community 分布,得出結論

需要多次反覆與IIm確認, 價格高昂

2. 我的 graph - rag 概念:從100題針對鞋子黴菌的問題集,提出實體與關係

	實體與關係數量	價格	速度	可回答範圍	實際上會被問到 但能回答的題目	效益
微軟 graph	ョ	迴		高	相同	
我的 graph			高		相同	高

3. 說明:目標為 "針對業務" 及 "效率原則", 所以與微軟相反, 我先得出我想要的結論(專注於回答哪個 community 的問題), 只將那個 community 實體與關係提出, 對於需要的問題, 不提取多餘的關係實體, 提升了效率, 也降低了成本。